

L'influence de l'âge dans le football

Louise Aslan, Raphaël Daudé

2024-11-07

Contents

1 Déclaration sur l'honneur	2
2 Introduction	2
3 Présentation de la population	2
4 Description des variables retenues	3
4.1 L'âge	3
4.2 Le poste	5
4.3 Le temps de jeu en minutes	7
4.4 Le pourcentage de passes réussies	8
5 Estimation ponctuelle et par intervalle de confiance de la moyenne d'âge	10
5.1 Estimation ponctuelle	10
5.2 Estimation par intervalle de confiance	10
6 Test de conformité sur le pourcentage de passes réussies	11
7 Comparaison de caractéristiques théoriques	13
7.1 Comparaison de moyennes	13
7.2 Comparaison de variances	15
8 Le test du Chi-deux	17
8.1 Tableau de contingence empirique	17
8.2 Tableau de contingence théorique	18
8.3 Tableau de profils lignes	18
8.4 Test du Chi-deux	19
Conclusion	20

1 Déclaration sur l'honneur

“Nous déclarons sur l'honneur que ce mémoire a été écrit de notre main, sans aide extérieure non autorisée, qu'il n'a pas été présenté auparavant pour évaluation et qu'il n'a jamais été publié, dans sa totalité ou en partie.

Toutes parties, groupes de mots ou idées, aussi limités soient-ils, y compris des tableaux, graphiques, cartes etc. qui sont empruntés ou qui font référence à d'autres sources bibliographiques sont présentés comme tels, sans exception aucune”.

Le 9 décembre 2024, Louise Aslan et Raphaël Daudé (L3 EID)

2 Introduction

La révélation de nouvelles jeunes stars du football combinée au déclin progressif des plus grands noms de ce sport laisse penser qu'il existe une corrélation négative entre l'âge et la performance footballistique. Au classement du ballon d'or 2024, 13 joueurs figurant sur la liste des 30 lauréats avaient 25 ans au plus. C'est 2 de plus par rapport au classement de l'année dernière, 3 de plus par rapport à 2022 ou encore 5 par rapport à 2021. S'ils ne représentent pas encore la majorité, la part des jeunes au sein de l'élite du football est tout de même passée de 26% à 46% en l'espace de 3 ans.

Pour autant, cela ne signifie pas que ce sont les équipes les plus jeunes qui s'emparent du plus de trophées. Valence, Toulouse ou encore Lecce avec des âges moyens respectivement de 24.19 ans, 24.16 ans et 25 ans en 2023 peinent à se hisser au sommet de leur championnat.

Les plus vieilles équipes comme Séville (âge moyen de 29,48 ans, 14e de Liga), Fulham (29,28 ans, 13e de Première Ligue) ou Cadix (29,55 ans, 18e de Liga) n'excellent pas davantage.

A l'inverse, des équipes avec des compositions hybrides à l'instar de Manchester City (26,55), Liverpool (27,17) ou encore le Bayern Munich (27,62) étaient respectivement classées 1er, 3e et 3e de leur championnat.

Conscients de la disparité des aptitudes techniques des joueurs, des ressources et infrastructures des clubs ou encore des ressources financières de ces derniers qui peuvent davantage influencer leurs résultats que le seul facteur de l'âge, nous avons décidé de focaliser notre attention sur la Ligue Des Champions (plus particulièrement la saison 2023-2024), la compétition réunissant les meilleurs clubs européens, afin de lisser au maximum ces différences de niveaux.

Dès lors, **dans quelle mesure l'âge des joueurs conditionne-t-il leurs performances ?** Nous tenterons d'apporter une réponse à cette question à travers l'analyse de plusieurs relations.

3 Présentation de la population

Afin de construire notre base de données, nous avons récolté des informations sur les joueurs de Ligue des Champions durant la saison 2023-2024 sur les sites officiels **fbref** et **whoscored**.

- <https://fbref.com/fr/comps/8/2023-2024/Stats-2023-2024-Champions-League>

- <https://www.whoscored.com/Regions/250/Tournaments/12/Seasons/9664/Stages/22686/PlayerStatistics/Europe-Champions-League-2023-2024>

A partir de la population totale (**cf. Remarque**), nous en avons dressé un échantillon aléatoire de 200 joueurs que nous avons incorporé dans notre base de données. Il s'agit donc d'un **tirage aléatoire simple sans remise (ou exhaustif)** pour lequel le taux de sondage est inférieur à 10% de la population totale.

On considère donc les X_i comme étant *i.i.d.*

Remarque: Il est utile de noter que bien que le site affiche une population totale de 727 joueurs, ce dernier ne prend uniquement en compte que ceux ayant joué au minimum une minute durant toute la compétition mais néglige une grande partie de ceux présents sur les feuilles de match et ayant fait les déplacements, qui ont contribué de près ou de loin au succès de leur équipe. Nous avons donc jugé important de les inclure **au sein de la population totale** car nul ne contredira l'importance de ces derniers du vestiaire jusqu'au banc en passant par l'entraînement.

Ainsi nous avons procédé à un échantillonnage non plus sur 727 joueurs mais sur plus de **2000**.

4 Description des variables retenues

Nous vidons tout d'abord l'environnement et importons notre base de données tout en vérifiant qu'il n'y a pas de valeurs manquantes:

```
# On s'assure de travailler dans un environnement propre
rm(list=ls())

# On importe notre base de données Excel tout en vérifiant qu'il n'y ait pas de valeurs manquantes
library(readxl)
Base <- read_excel('Base1.xlsx')
anyNA(Base)
```

```
## [1] FALSE
```

```
attach(Base)
View(Base)
Total<-sum

# On fixe également le nombre de décimales
options(digits=2)
```

Les variables présentes au sein de cette base sont: *le poste, l'âge, les titularisations, le temps de jeu (en minutes), les buts, les passes décisives, les cartons jaunes, les cartons rouges, les buts escomptés, le pourcentage de passes réussies, les duels aériens gagnés, les trophées MOTM (Man of the Match)* ainsi que *la note*.

Dans le cadre de notre étude, nous avons décidé de nous focaliser sur l'étude des 4 variables suivantes :

4.1 L'âge

La première variable que nous avons choisie est l'**âge des joueurs** qui constitue tout l'objet de notre étude. L'objectif est de déceler si certaines tranches d'âge se démarquent et, le cas échéant, s'il existe un âge optimal pour jouer et performer en Ligue des Champions.


Il s'agit d'une **variable quantitative discrète** que nous représentons par un **diagramme en bâtons**.

```
age<- Age

# Répartition de l'âge des joueurs :
addmargins(prop.table(table(age)),FUN=Total)
```

```
## age
## 17 18 19 20 21 22 23 24 25 26 27 28 29
## 0.005 0.005 0.010 0.015 0.045 0.050 0.055 0.085 0.115 0.065 0.100 0.075 0.065
## 30 31 32 33 34 35 36 38 41 Total
## 0.080 0.080 0.060 0.005 0.025 0.020 0.025 0.010 0.005 1.000
```


```
# Construction du diagramme en bâtons
plot(table(age),xlab="Âge",ylab="Nombre de joueurs ",
      main=" Répartition de l'âge des joueurs ")
```



Nous cherchons également à avoir un aperçu plus lisse à l'aide de la densité.

```
# Densité
dens_age <- density(age)
plot(dens_age, main = "Densité de l'âge des joueurs",
      xlab = "Âge", ylab = "Densité", col = "deeppink", lwd = 2)
```

Densité de l'âge des joueurs



Nous observons que la représentation de l'âge des joueurs en Ligue des Champions prend une forme de “cloche”.

On observe également que les joueurs évoluant en Ligue des Champions sont principalement âgés de 24 à 27 ans.

Cela peut sembler logique du fait que c'est à ce moment que ces derniers commencent à acquérir de l'expérience et à atteindre une forme optimale, leur permettant ainsi d'enchaîner les matchs.

4.2 Le poste

Il s'agit d'une **variable qualitative nominale**. L'étude de cette variable nous permettra de dégager des sous-groupes.

Nous commençons par définir notre variable “**Position**”, qui représente le poste de nos 200 joueurs.

```
Base$Position <- factor(Base$Position,  
  levels = c("A", "M", "D", "G"),  
  labels = c("Attaquants", "Milieux", "Défenseurs", "Gardiens"))
```

Il s'agit d'une **variable qualitative discrète** que nous représentons par le biais d'un **diagramme circulaire**.

```
# Tableau d'effectifs
position <- Base$Position
Total<-sum
addmargins(table(position), FUN=Total)
```

```
## position
## Attaquants      Milieux Défenseurs      Gardiens      Total
##           58           62           64           16           200
```


```
# Tableau de fréquences
table1 <- prop.table(table(position))
addmargins((table1),FUN=Total)
```

```
## position
## Attaquants      Milieux Défenseurs      Gardiens      Total
##           0.29           0.31           0.32           0.08           1.00
```

```
# On dresse notre diagramme circulaire
prop1 <- paste(rownames(table1),round(table1,3),'%')
colours1=c("steelblue","blue", "skyblue2", "lightblue")

pie(prop.table(table(position)), main='Répartition des joueurs par postes', col=colours1, labels = prop
```

Répartition des joueurs par postes



Nous observons que le pourcentage de chaque poste est relativement équivalent, sauf dans le cas des gardiens.

Cela semble logique, puisque dans chaque équipe nous observons qu'un seul gardien titulaire contre 3 à 4 joueurs pour les autres postes.

4.3 Le temps de jeu en minutes

Déterminée par l'entraîneur, cette variable est la résultante des performances globales du joueur peu importe son poste.

Par exemple, le temps de jeu varie en fonction: des buts et passes décisives pour les attaquants et milieux, des tacles et interceptions pour les défenseurs ou encore des clean sheet pour les gardiens.

Elle a l'avantage d'être représentative de l'échantillon tout entier. Il s'agit d'une **variable quantitative discrète**.

Par soucis de clarté, nous avons regroupé les valeurs par classes de 100 minutes afin d'éviter d'avoir une trop lourde distribution.

```
borne1 <-seq(0,1200,100)
Minutes<-cut(Mins, borne1)

# Tableau d'effectifs
addmargins(table(Minutes), FUN= Total)
```


```
## Minutes
##      (0,100]      (100,200]      (200,300]      (300,400]
##           0           1           6          15
##      (400,500]      (500,600]      (600,700]      (700,800]
##          47          55          24          21
##      (800,900]      (900,1e+03]      (1e+03,1.1e+03]      (1.1e+03,1.2e+03]
##          11          11           8           1
##      Total
##      200
```

```
# Tableau de fréquences
addmargins(prop.table(table(Minutes)),FUN=Total)
```

```
## Minutes
##      (0,100]      (100,200]      (200,300]      (300,400]
##      0.000      0.005      0.030      0.075
##      (400,500]      (500,600]      (600,700]      (700,800]
##      0.235      0.275      0.120      0.105
##      (800,900]      (900,1e+03]      (1e+03,1.1e+03]      (1.1e+03,1.2e+03]
##      0.055      0.055      0.040      0.005
##      Total
##      1.000
```

```
# On représente la distribution à l'aide d'un histogramme car il s'agit d'une
# variable quantitative discrète regroupée en classes
hist(Mins,
     main='Distribution du temps de jeu des joueurs',
     xlab='Temps de jeu en minutes', ylab='nombre de joueurs', breaks=11, col='skyblue')
```

Distribution du temps de jeu des joueurs



On remarque que la majorité des joueurs ont un temps de jeu compris entre 500 et 600 minutes.

Ce résultat reste tout de même à nuancer étant donné que les équipes ne s'arrêtent pas au même stade de la compétition.

Un joueur titulaire à Manchester United dont l'équipe a fini dernière de son groupe en phase de poules lors de la dernière édition finira forcément avec un temps de jeu total inférieur à celui d'un titulaire du Borussia Dortmund, finaliste de la dernière édition.

4.4 Le pourcentage de passes réussies

De la même manière que pour le temps de jeu, à défaut de prendre les nombres de buts ou passes décisives qui ne reflèteraient les performances que d'une partie de la population (principalement les attaquants et milieux), nous avons choisi de nous focaliser sur une variable fidèle à l'équipe entière.

Il s'agit également une **variable quantitative discrète** pour laquelle nous avons groupé les réalisations par classes de 10 (%).

```
# Rstudio ne parvenant pas à lire les valeurs numériques associées à la variable Passes,  
#on utilise la fonction as.numeric() avant de les regrouper en classes  
PR <-as.numeric(Passes)  
borne2 <-seq(0,100,10)  
PassesR<-cut(PR, borne2)
```




```
# Tableau d'effectifs
addmargins(table(PassesR), FUN= Total)
```

```
## PassesR
## (0,10] (10,20] (20,30] (30,40] (40,50] (50,60] (60,70] (70,80]
##      0      0      0      0      0      0      13      53
## (80,90] (90,100] Total
##      105      29      200
```

```
# Tableau de fréquences
addmargins(prop.table(table(PassesR)), FUN=Total)
```

```
## PassesR
## (0,10] (10,20] (20,30] (30,40] (40,50] (50,60] (60,70] (70,80]
## 0.000 0.000 0.000 0.000 0.000 0.000 0.065 0.265
## (80,90] (90,100] Total
## 0.525 0.145 1.000
```

```
# Histogramme
hist(PR,
     main='Pourcentage de passes réussies',
     xlab='taux de passes réussies en %', ylab='nombre de joueurs', breaks=9, col='orange3')
```



Si peu de joueurs réussissent 100% de leurs passes en LDC, la précision de ces derniers ne descend jamais en dessous de 60%. La majorité d'entre eux les réussissent avec 85-90% de précision.

5 Estimation ponctuelle et par intervalle de confiance de la moyenne d'âge

5.1 Estimation ponctuelle

Un estimateur naturel de la moyenne théorique m est la moyenne empirique $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$.
Une estimation ponctuelle de m serait: $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

```
# Estimation ponctuelle
xbar <-mean(Age)
print(paste("Une estimation ponctuelle de la moyenne d'âge des 200 meilleurs joueurs de LDC est",
            round(xbar, digits=2), 'ans'))
```

```
## [1] "Une estimation ponctuelle de la moyenne d'âge des 200 meilleurs joueurs de LDC est 27.26 ans"
```

5.2 Estimation par intervalle de confiance

On cherche à estimer la **moyenne théorique de l'âge des joueurs** par intervalle de confiance avec σ inconnu et $n \geq 30$.

Par ailleurs, on observe graphiquement une forme en cloche et une symétrie, donc on peut approximer notre échantillon par une **loi normale**. Soit $(X_1, \dots, X_n) \sim \mathcal{N}(m, \sigma)$ pour $i = 1, 2, \dots, 200$.

D'après la **Loi des Grands Nombres**, $\bar{X}$ est un estimateur convergent de m avec $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
Comme $X \sim \mathcal{N}(m, \sigma^2)$, alors $\bar{X} \sim \mathcal{N}(m, \frac{\sigma}{\sqrt{n}})$.

On centre et on réduit: $\frac{\bar{X}-m}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0, 1)$

Or, $S' \xrightarrow{P} \sigma$, donc $\frac{S'}{\sigma} \xrightarrow{P} 1$, donc par application du **théorème de Slutsky**, on a :
 $\frac{\bar{X}-m}{\frac{\sigma}{\sqrt{n}}} \times \frac{\sigma}{S'} \sim \mathcal{N}(0, 1) \Rightarrow \frac{\bar{X}-m}{\frac{S'}{\sqrt{n}}} \sim \mathcal{N}(0, 1)$.

$$\text{D'où: } P\left(u_{\frac{\alpha}{2}} \leq \frac{\bar{X}-m}{\frac{S'}{\sqrt{n}}} \leq u_{1-\frac{\alpha}{2}}\right) = 1 - \alpha$$

$$\Leftrightarrow P\left(-u_{1-\frac{\alpha}{2}} \leq \frac{\bar{X}-m}{\frac{S'}{\sqrt{n}}} \leq u_{1-\frac{\alpha}{2}}\right) = 1 - \alpha$$

$$\Leftrightarrow P\left(\bar{X} - u_{1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}} \leq m \leq \bar{X} + u_{1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}}\right) = 1 - \alpha$$

Ce qui nous donne l'intervalle de confiance: $IC = \left[\bar{X} - u_{1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}}, \bar{X} + u_{1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}}\right]$

Au niveau 95% ($\alpha = 0,05$)

```
xbar <-mean(Age)
a1 = xbar - qnorm(0.975)*sd(Age)/sqrt(200)
b1 = xbar + qnorm(0.975)*sd(Age)/sqrt(200)
print(paste("On a alors IC(95%) = [", round(a1, digits=2), ',', round(b1, digits=2), ']'))
```

```
## [1] "On a alors IC(95%) = [ 26.68 , 27.85 ]"
```

La moyenne d'âge de notre population a donc 95% de chance de se situer dans l'intervalle [26.68, 27.85].

Au niveau 90% ($\alpha = 0,1$) Ici $\alpha = 0.1$

```
xbar <-mean(Age)
a1 = xbar - qnorm(0.95)*sd(Age)/sqrt(200)
b1 = xbar + qnorm(0.95)*sd(Age)/sqrt(200)
print(paste("On a donc IC(90%) = [", round(a1, digits=2), ',', round(b1, digits=2), ']'))
```

```
## [1] "On a donc IC(90%) = [ 26.77 , 27.76 ]"
```

On peut affirmer avec une confiance de 90% que la moyenne d'âge de la population se situe dans l'intervalle [26.77, 27.76].

6 Test de conformité sur le pourcentage de passes réussies

La Ligue des Champions supposée réunir l'élite européenne dans la mesure où la plupart des joueurs y évoluant sont issus des 5 grands championnats (Ligue 1, Serie A, Bundesliga, la Liga, Premier League), on cherche alors à vérifier, en se basant sur le pourcentage de passes réussies, la validité de sa réputation.

En ayant choisi la Premier League comme la représentante des 5 géants en raison de sa compétitivité sans équivoque, nous cherchons à savoir si le taux moyen de passes réussies en LDC notée m est supérieure à celle de Premier League.

A partir des données du site fbref, nous trouvons que la moyenne de passes réussies des joueurs en Premier League était de **76.53%** lors du championnat 2023-2024.

Considérons que notre m_0 correspond à ce pourcentage, soit $m_0 = 0.7653$.

On privilégie alors le jeu d'hypothèses suivant : $\begin{cases} H_0 : m = m_0 \\ H_1 : m > m_0 \end{cases}$ avec $m_0 = 0.7653$

Soit X la variable aléatoire représentant le taux de passes réussies. On a $(X_1, \dots, X_n) \sim \text{i.i.d } (m, \sigma)$ pour $i = 1, 2, \dots, 200$ avec $n \geq 30$ et σ inconnu.

La **Région critique** correspond à l'ensemble des réalisations de la statistique de test T_n pour lesquelles on rejette H_0 . Puisque nous sommes dans le cas d'un **test unilatéral à droite**, elle est donnée par :

$W = \{(x_1, x_2, \dots, x_n) : T_n > c\}$, avec T_n la **statistique de test** et c la **valeur critique**.

Dans notre cas : $T_n = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$.

Nous rejetons donc H_0 si $\bar{X} > c$ au seuil $\alpha = 5\%$, car cela signifierait que la moyenne de passes réussies en LDC observée est trop importante pour ne pas rejeter l'hypothèse d'égalité avec celle de Premier League.

De plus, on a $n = 200 > 30$, nous pouvons donc utiliser le **Théorème Central Limite**:

$$\bar{X} \xrightarrow{d} N\left(m, \frac{\sigma}{\sqrt{n}}\right) \Rightarrow \frac{\bar{X}-m}{\frac{\sigma}{\sqrt{n}}} \xrightarrow{d} N(0, 1)$$

On sait également que $S' \xrightarrow{p} \sigma$, d'où $\frac{\sigma}{S'} \xrightarrow{p} 1$

D'après le **théorème de Slutsky**: $\frac{\bar{X}-m}{\frac{\sigma}{\sqrt{n}}} \times \frac{\sigma}{S'} \xrightarrow{d} N(0, 1)$. Soit: $U = \frac{\bar{X}-m}{\frac{S'}{\sqrt{n}}} \xrightarrow{d} N(0, 1)$

En utilisant le **Contrainte de Première Espèce**, on a: $P(D_1|H_0) = \alpha \Leftrightarrow P(\bar{X} > c|m = m_0) = \alpha$

$$\Leftrightarrow P\left(U > \frac{c-m}{\frac{S'}{\sqrt{n}}} \mid m = m_0\right) = \alpha$$

$$\Leftrightarrow 1 - P\left(U \leq \left(\frac{c-m_0}{\frac{S'}{\sqrt{n}}}\right)\right) = \alpha$$

$$\Leftrightarrow -P\left(U \leq \left(\frac{c-m_0}{\frac{S'}{\sqrt{n}}}\right)\right) = \alpha - 1$$

$$\Leftrightarrow P\left(U \leq \left(\frac{c-m_0}{\frac{S'}{\sqrt{n}}}\right)\right) = 1 - \alpha$$

$$\text{On a alors: } \frac{c-m_0}{\frac{S'}{\sqrt{n}}} = u_{1-\alpha}$$

$$\text{Soit la valeur critique équivaut à : } c = m_0 + u_{1-\alpha} \times \frac{S'}{\sqrt{n}}$$

Dans un test unilatéral à droite, on a: $p\text{-value} = P(T_n > t_{obs} | H = H_0)$

Avec: T_n la statistique de test, t_{obs} la statistique observée, et $p\text{-value}$ la **probabilité si H_0 est vraie d'observer une statistique de test aussi extrême que celle observée, ou encore la probabilité de rejeter à tort H_0 compte tenu de la statistique observée.**

```
# On effectue le test de conformité
PR <- as.numeric(Passes)
t.test(PR, mu=0.7653, alternative='greater')
```

```
##
## One Sample t-test
##
## data: PR
```

```
## t = 158, df = 199, p-value <2e-16
## alternative hypothesis: true mean is greater than 0.77
## 95 percent confidence interval:
##      82 Inf
## sample estimates:
## mean of x
##          83
```

Pour $\alpha = 0,05$, $p\text{-value} = 2e-16 < \alpha$. Autrement dit, **pour un niveau de confiance de 95%**, nous rejetons l'hypothèse H_0 à savoir que les joueurs de LDC et de Premier League ont le même pourcentage de passes réussies.

Nous pouvons en conclure qu'au seuil de 5%, les joueurs de Ligue des Champions ont un pourcentage de passes réussies meilleurs que les joueurs de Premier League.

Ce résultat renforce l'idée que l'exigence de la Ligue des Champions oblige les joueurs à maintenir un niveau de performance technique exceptionnel.

Une hypothèse intéressante à explorer serait que, en raison du niveau de jeu élevé et de l'enjeu important, les équipes seraient amenées à entreprendre moins de passes risquées, ce qui contribuerait à leur efficacité globale en termes de passes réussies.

7 Comparaison de caractéristiques théoriques

7.1 Comparaison de moyennes

On veut comparer la moyenne d'âge des milieux m_X avec celle des défenseurs m_Y . L'âge d'un joueur peut-il influencer sur son positionnement ?

Soient X_i la variable aléatoire représentant l'âge des milieux et Y_i celle représentant l'âge des défenseurs.

On a $X_i \text{ i.i.d } \sim (m_X, \sigma_X)$ et $Y_i \text{ i.i.d } \sim (m_Y, \sigma_Y)$ avec n_X et $n_Y > 30$.

On suppose l'égalité des deux moyennes comme hypothèse nulle H_0 et deux moyennes différentes comme hypothèse alternative H_1 :

$$\begin{cases} H_0 : m_X = m_Y \\ H_1 : m_X \neq m_Y \end{cases}$$

Il s'agit d'un **test bilatéral**.

Nous sommes dans le cas où les variances théoriques sont **inconnues** et $n_X, n_Y > 30$. Nous effectuons un premier test de variances pour conclure à l'égalité ou non de ces dernières.

```
# On crée nos deux sous-groupes
base1 <- subset(Base, Position=='Milieux')
base2 <- subset(Base, Position=='Défenseurs')
x <- base1$Age
y <- base2$Age
varx <- var(x)
```

```

vary <- var(y)
var.test(x,y,alternative='two.sided')

```

```

##
## F test to compare two variances
##
## data: x and y
## F = 0.9, num df = 61, denom df = 63, p-value = 0.8
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
## 0.57 1.56
## sample estimates:
## ratio of variances
## 0.94

```

La p-value étant de 0.8, **on ne peut pas conclure** à l'égalité des variances aux seuils de 5% et 10%.

On utilise la statistique de test: $\bar{X} - \bar{Y} \xrightarrow{d} N(m_X - m_Y, \sqrt{\frac{\sigma_X^2}{n_X} + \frac{\sigma_Y^2}{n_Y}})$

Règle de décision: On rejette H_0 au seuil α si: $\bar{X} - \bar{Y} < c_1$ ou $\bar{X} - \bar{Y} > c_2$.

En effet, étant dans le cas d'un test bilatéral, on rejette l'hypothèse nulle aussi bien dans le cas où la différence entre les deux statistiques serait inférieure à une valeur critique c_1 (la différence est suffisamment négative pour rejeter H_0) comme dans celui où la différence excéderait une autre valeur critique c_2 ($\bar{X}$ est suffisamment supérieur à $\bar{Y}$ pour rejeter H_0).

On sait que: $\frac{S_X'^2}{n_X} + \frac{S_Y'^2}{n_Y} \xrightarrow{p} \frac{\sigma_X^2}{n_X} + \frac{\sigma_Y^2}{n_Y}$

D'après le théorème de continuité: $\sqrt{\frac{\sigma_X^2}{n_X} + \frac{\sigma_Y^2}{n_Y}} \xrightarrow{p} \sqrt{\frac{S_X'^2}{n_X} + \frac{S_Y'^2}{n_Y}}$, d'où: $\sqrt{\frac{\frac{\sigma_X^2}{n_X} + \frac{\sigma_Y^2}{n_Y}}{\frac{S_X'^2}{n_X} + \frac{S_Y'^2}{n_Y}}} \xrightarrow{p} 1$

En utilisant le théorème de Slutsky on obtient: $U = \frac{(\bar{X} - \bar{Y}) - (m_X - m_Y)}{\sqrt{\frac{\sigma_X^2}{n_X} + \frac{\sigma_Y^2}{n_Y}}} \times \sqrt{\frac{\frac{\sigma_X^2}{n_X} + \frac{\sigma_Y^2}{n_Y}}{\frac{S_X'^2}{n_X} + \frac{S_Y'^2}{n_Y}}} \xrightarrow{d} N(0, 1)$

D'où : $U = \frac{(\bar{X} - \bar{Y}) - (m_X - m_Y)}{\sqrt{\frac{S_X'^2}{n_X} + \frac{S_Y'^2}{n_Y}}} \xrightarrow{d} N(0, 1)$

Et sous H_0 : $U = \frac{(\bar{X} - \bar{Y})}{\sqrt{\frac{S_X'^2}{n_X} + \frac{S_Y'^2}{n_Y}}} \xrightarrow{d} N(0, 1)$

On en déduit alors: $c_2 = -c_1 = u_{1-\frac{\alpha}{2}} \sqrt{\frac{S_X'^2}{n_X} + \frac{S_Y'^2}{n_Y}}$

```

# On reprend les deux sous-groupes ci-dessus
mX <- mean(x)
mY <- mean(y)
t.test(x,y,alternative='two.sided', var.equal=FALSE)

```

```
##
```

```
## Welch Two Sample t-test
##
## data: x and y
## t = -2, df = 124, p-value = 0.08
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
## -2.92 0.17
## sample estimates:
## mean of x mean of y
##      26      28
```

Ce résultat nous montre qu'au seuil de 5%, on ne peut rejeter l'hypothèse selon laquelle les milieux et défenseurs ont des moyennes d'âge équivalentes.

En revanche, au seuil de 10%, la probabilité de rejeter à tort l'hypothèse d'obtenir des moyennes d'âges égales entre les milieux et défenseurs est trop faible ($p\text{-value} = 8,1\% < 10\%$), on doit donc la rejeter. Ainsi, même si la différence n'est pas extrême, nous avons suffisamment d'éléments pour conclure que les milieux et défenseurs n'ont en moyenne pas le même âge.

Cela peut s'expliquer du fait des exigences physiques du poste de milieu de terrain qui assure la liaison entre la défense et l'attaque, nécessitant des aller-retour fréquents sur de grandes distances. Un profil plus jeune et dynamique sera donc privilégié à ce poste.

A l'inverse, les défenseurs ont un rôle davantage focalisé sur la protection de leur propre zone, avec des efforts concentrés sur des périodes plus courtes.

Bien que le poste exige une toute aussi bonne condition physique qu'au milieu de terrain, les déplacements sont souvent moins dispersés et plus centrés autour de la zone de but. De plus, les défenseurs mettent souvent plus de temps à mûrir, étant donné que la compréhension tactique, l'anticipation des offensives adverses ou encore la gestion du jeu sous pression se perfectionnent avec le temps.

On remarque d'ailleurs que c'est à ce poste que le brassard de capitaine est le plus souvent attribué : Sergio Ramos, Thiago Silva, Marquinhos, Virgil Van Dijk, Piqué ou encore Bonucci ont tous été sollicité pour leur expérience.

7.2 Comparaison de variances

On veut comparer la variance du temps de jeu des attaquants et des défenseurs. L'entraîneur fait-il plus varier le temps de jeu de ses joueurs en fonction de leur poste ?

Soient σ_X et σ_Y les variances de temps de jeu respectivement des attaquants et défenseurs. Dans notre jeu d'hypothèse, l'hypothèse de base repose sur **l'égalité des deux variances**, suggérant que le temps de jeu des attaquants varie autant que celui des défenseurs. On a ainsi:

$$\begin{cases} H_0 : \sigma_X = \sigma_Y \\ H_1 : \sigma_X \neq \sigma_Y \end{cases}$$

Il s'agit d'un test **bilatéral**.

On a $s_X'^2$ et $s_Y'^2$ les variances empiriques corrigées des deux sous-groupes et n_X and n_Y les populations respectives d'attaquants et de défenseurs.

On rappelle que si $X = \frac{(n_X-1)S_X'^2}{\sigma_X^2} \sim \chi_{n_X-1}^2$ et $Y = \frac{(n_Y-1)S_Y'^2}{\sigma_Y^2} \sim \chi_{n_Y-1}^2$ et X et Y indépendantes, alors **la statistique de test** pour la comparaison de deux variances est:

$$F = \frac{\frac{X}{\frac{n_X-1}{n_Y-1}}}{\frac{\frac{(n_X-1)S_X'^2}{\sigma_X^2}}{\frac{(n_Y-1)S_Y'^2}{\sigma_Y^2}}} = \frac{\frac{S_X'^2}{\sigma_X^2}}{\frac{S_Y'^2}{\sigma_Y^2}} = \frac{S_X'^2}{\sigma_X^2} \times \frac{\sigma_Y^2}{S_Y'^2}$$

Sous l'hypothèse H_0 : $\sigma_X^2 = \sigma_Y^2$. D'où:

$$F = \frac{S_X'^2}{S_Y'^2} = \frac{\frac{n_X \times S_X^2}{n_X-1}}{\frac{n_Y \times S_Y^2}{n_Y-1}} \sim F(n_X-1, n_Y-1)$$

Règle de décision: On rejete H_0 au seuil α si $F < c_1$ ou $F > c_2$

Contrainte de première espèce: $P(c_1 < F < c_2 | \sigma_1^2 = \sigma_2^2) = 1 - \alpha \Rightarrow P\left(c_1 < F = \frac{S_1'^2}{S_2'^2} < c_2\right) = 1 - \alpha$

On en déduit alors : $c_1 = f_{n_X-1, n_Y-1; \frac{\alpha}{2}} = \frac{1}{f_{n_Y-1, n_X-1; 1-\frac{\alpha}{2}}}$ et $c_2 = f_{n_X-1, n_Y-1; 1-\frac{\alpha}{2}}$ avec $f_{v_1, v_2; p}$ le quantile d'ordre p de la loi $F(v_1, v_2)$.

```
base1 <- subset(Base, Position=='Attaquants')
base2 <- subset(Base, Position=='Défenseurs')
x <- base1$Mins
y <- base2$Mins
varx <- var(x)
vary <- var(y)
var.test(x,y,alternative='two.sided')
```

```
##
## F test to compare two variances
##
## data: x and y
## F = 1, num df = 57, denom df = 63, p-value = 0.3
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
## 0.77 2.13
## sample estimates:
## ratio of variances
## 1.3
```

La probabilité critique étant relativement supérieure aux seuils de 5% et 10%, il n'y a pas assez de preuve pour rejeter l'hypothèse de départ à savoir que les attaquants et défenseurs ont une variance similaire. Autrement dit, la probabilité de rejeter cette hypothèse à tort est relativement élevée.

De manière générale, on aurait pu s'attendre à ce que les entraîneurs fassent davantage tourner leurs attaquants dans le but d'apporter un souffle d'explosivité, tout en cherchant à ne pas porter atteinte à la cohésion défensive en maintenant une structure homogène.

L'exemple du FC Barcelone en ce début de saison 2024 illustre parfaitement ce dernier point. L'équipe d'Hansi Flick a provoqué plus de 77 hors jeu depuis le début de la saison toutes compétitions confondues.

Sur leurs victoires 4-1 contre le Bayern Munich ou encore 4-0 contre le Real Madrid lors du dernier Clasico, aucun changement n'a été effectué en défense durant les deux matchs.

Cependant, l'entraîneur est également contraint par les choix tactiques de l'autre équipe. Dans le cas d'un pressing offensif adverse, ses décisions seront plus susceptibles d'être tournées en faveur d'une défense renforcée, que ce soit par le biais de changements ou d'un dispositif réajusté.

De ce fait, **dans le contexte de la Ligue des Champions** avec des phases éliminatoires où chaque changement peut être décisif, les entraîneurs n'hésitent pas à multiplier les rotations de leur équipe pour préserver la forme physique des joueurs, d'autant plus que les effectifs à haut niveau sont plus grands. Cela vaut pour tous les joueurs indépendamment de leur poste.

Au final, on peut conclure que le temps de jeu varie de la même manière pour les attaquants et défenseurs en Ligue des Champions.

8 Le test du Chi-deux

Nous souhaitons ici tester l'indépendance (ou non) de l'âge des joueurs et de leur poste.

De prime abord, on pourrait penser que les défenseurs sont forcément plus âgés que les attaquants notamment car ces derniers doivent davantage solliciter leur vitesse et puiser dans leur capacité d'accélération qui, dans la plupart des cas, atteint son paroxysme durant leur jeune âge.

Cependant, des attaquants vedètes à l'instar de Cristiano Ronaldo, Robert Lewandowski ou encore Karim Benzema qui a obtenu son premier Ballon d'Or à 34 ans, semblent nous démontrer tout le contraire.

Dans le même temps, l'amélioration technique des défenseurs conjuguée à la demande grandissante de latéraux rapides et explosifs témoignent de la capacité de la jeune génération à assumer ce poste de taulier, et ce en dépit de leur manque d'expérience.

C'est notamment le cas du finaliste de Ligue des Champions de l'année 2023-2024, le Borussia Dortmund, qui a joué cette compétition avec une défense titulaire âgée d'environ 25 ans.

Le test nous permettrait alors de tirer des conclusions sur la gestion des effectifs, les tendances stratégiques des clubs, et les exigences spécifiques des postes en fonction de l'âge des joueurs.

8.1 Tableau de contingence empirique

On cherche à obtenir un premier aperçu du lien qui unit l'âge des joueurs avec leur position sur le terrain dans notre échantillon de 200 joueurs. On dresse pour cela un **tableau de contingence empirique**

```
options(digits=2)

# De manière à obtenir des effectifs théoriques supérieur à 4 pour la suite du test,
# on regroupe les valeurs d'âge en différentes classes
âge <- cut(Age, breaks = c(16, 24, 29, 41), labels = c('[17 à 24]', '[25 à 29]', '[30 à 41]'))
Contingence_emp <- table(âge, Position)
addmargins(Contingence_emp, FUN=Total)

## Margins computed over dimensions
## in the following order:
## 1: âge
## 2: Position
```

```
##           Position
## âge      A   D   G   M Total
## [17 à 24] 19  14   0  21   54
## [25 à 29] 21  29   9  25   84
## [30 à 41] 18  21   7  16   62
## Total     58  64  16  62  200
```

A partir de cette première observation, on remarque par exemple une majorité de défenseurs par rapport aux autres postes à partir de 25 ans.

8.2 Tableau de contingence théorique

```
chisq <- chisq.test(âge, Position, correct=FALSE)
```

```
## Warning in chisq.test(âge, Position, correct = FALSE): L'approximation du Chi-2
## est peut-être incorrecte
```

```
tab_exp<-chisq$expected
addmargins(tab_exp)
```

```
##           Position
## âge      A   D   G   M Sum
## [17 à 24] 16 17  4.3 17  54
## [25 à 29] 24 27  6.7 26  84
## [30 à 41] 18 20  5.0 19  62
## Sum       58 64 16.0 62 200
```

8.3 Tableau de profils lignes

```
Total <- sum
addmargins(prop.table(addmargins(Contigence_emp, 1, FUN=Total), 1), 2, FUN=Total)
```

```
##           Position
## âge      A   D   G   M Total
## [17 à 24] 0.35 0.26 0.00 0.39 1.00
## [25 à 29] 0.25 0.35 0.11 0.30 1.00
## [30 à 41] 0.29 0.34 0.11 0.26 1.00
## Total     0.29 0.32 0.08 0.31 1.00
```

Par exemple, on remarque que parmi les 200 joueurs observés, aucun gardien n'est âgé de moins de 25 ans.

8.4 Test du Chi-deux

On cherche à savoir s'il existe une **corrélation entre l'âge des joueurs et leur poste**. On note X la variable représentant l'âge du joueur et Y son poste

On pose ainsi l'hypothèse nulle selon laquelle **les variables sont indépendantes**:

$$\begin{cases} H_0 : X \perp Y \\ H_1 : \text{les deux variables sont dépendantes} \end{cases}$$

On utilise **la statistique de test** suivante:

$$\Delta = \sum_{i=1}^l \sum_{j=1}^c \frac{(n_{ij} - t_{ij})^2}{t_{ij}} \xrightarrow{d} \chi_{(l-1)(c-1)}^2 \text{ avec } l \text{ le nombre de lignes et } c \text{ le nombre de colonnes.}$$

Avec: $t_{ij} = \frac{n_{i.} n_{.j}}{n}$, et n_{ij} le nombre de joueurs ayant pour âge i et poste j .

En ayant regroupé les âges par classes, on a également bien $t_{ij} \geq 4 \forall i, j$

Règle de décision: On rejette H_0 au seuil α si $\Delta > c$.

En effet, dans ce cas la somme des écarts entre les données observées et attendues/ théoriques sous l'hypothèse d'indépendance est trop importante pour ne pas rejeter cette dernière.

Ce qui donne comme **contrainte de première espèce** : $P(D_1|H_0) = \alpha \Leftrightarrow P(\Delta > c|X \perp Y) = \alpha$

On en déduit **la valeur critique**: $c = \chi_{(l-1)(c-1); 1-\alpha}^2$

Ici, $l = 3$ et $c = 4$, d'où $c = \chi_{6; 1-\alpha}^2$

Pour $\alpha = 0,05$, $c = 12,59$

Pour $\alpha = 0,1$, $c = 2,20$

```
test <- chisq.test(âge, Position ,correct=FALSE)
```

```
## Warning in chisq.test(âge, Position, correct = FALSE): L'approximation du Chi-2
## est peut-être incorrecte
```

```
test
```

```
##
## Pearson's Chi-squared test
##
## data: âge and Position
## X-squared = 10, df = 6, p-value = 0.1
```

Les résultats nous montrent **qu'au seuil de 5%**, avec une p-value de 0.1, il n'existe pas assez de preuves pour pouvoir rejeter l'hypothèse d'indépendances des deux variables.

En revanche, **au seuil de 10%**, le test nous permet de rejeter l'hypothèse H_0 . Autrement dit, il y a assez de preuves pour affirmer que le poste auquel évolue un joueur **n'est pas indépendant de son âge**.

Nous avons déjà obtenu des prémises de cette conclusion lors de la comparaison des moyennes d'âge des milieux et défenseurs, en décelant une jeunesse davantage présente chez les milieux de terrain.

Désormais, nous pouvons corroborer l'incidence de l'âge sur le poste du joueur en Ligue des Champions.

Conclusion

Cette étude nous a permis **d'examiner l'importance de l'âge dans les performances des joueurs de football en Ligue des Champions** en nous penchant sur l'analyse de quatre variables : l'âge, le poste, le temps de jeu et le pourcentage de passes réussies.

En réponse à notre question initiale sur l'impact de l'âge sur les performances des joueurs, nos résultats dévoilent que **l'âge moyen** a tendance à se situer autour de **26-27 ans**, soit au milieu de la carrière du joueur (étant donné qu'elle débute en moyenne à 18 ans et se termine vers 35 ans).

Cela suggère que performer au plus haut niveau nécessite un **équilibre entre une expérience aguerrie et des capacités physiques optimales**, deux critères qui tendent parfois à s'opposer.

Cette observation est particulièrement pertinente pour les milieux de terrain, devant combiner expérience pour limiter les erreurs coûteuses (offensivement comme défensivement), et endurance pour gérer les efforts (offensifs et défensifs) sur toute la durée du match.

Cependant, ces exigences varient selon les postes. Par exemple, les gardiens de but, bien qu'ils doivent maintenir des qualités athlétiques comme des réflexes rapides, s'appuient davantage sur leur expérience pour leur placement, leurs anticipations ou encore la gestion de leur défense lors des coups de pied arrêtés.

Ces disparités entre postes nous ont conduit à étudier la **relation entre l'âge et le poste** des joueurs. Bien que des tendances aient été identifiées en faveur d'un lien entre les deux variables, nous ne pouvons conclure à une dépendance systématique, les résultats étant significatifs à un seuil de 10 % mais non à 5 %.

Ainsi, bien que notre analyse mette en lumière une corrélation entre l'âge et les performances, **cette dernière doit être interprétée avec prudence**. En effet, de nombreux autres facteurs que nous avons déjà pu citer en introduction tels que la préparation physique, les infrastructures des clubs, le talent intrinsèque des joueurs ou encore le mercato jouent un rôle tout aussi, si ce n'est encore plus crucial dans la compétitivité des équipes.

Au final, cette étude avait pour objectif de fournir des perspectives d'études sur l'impact de l'âge dans le football professionnel, tout en rappelant que ce critère ne peut à lui seul expliquer l'ensemble des différences de performances observées.